


Reconnaître des chiffres manuscrits

Un modèle entraîné en laboratoire tient-il face à de vraies photos ?

Entraînement sur MNIST, puis confrontation à des chiffres écrits sur papier et photographiés



Document expliqué depuis zéro : aucune connaissance préalable n'est nécessaire.

Sommaire

1. L'objectif en une phrase
2. MNIST : le jeu de référence
3. Le modèle : un réseau de neurones
4. Entraînement et performance sur MNIST
5. Un jeu de test « réel » : des chiffres sur papier
6. Le prétraitement : d'une photo à une image utilisable
7. Comparaison des performances
8. Analyse détaillée des résultats
9. Que retenir, et comment faire mieux
10. Glossaire

1. L'objectif en une phrase

On veut construire un programme qui **regarde l'image d'un chiffre manuscrit** (un 0, un 1, ... un 9) et **devine de quel chiffre il s'agit**. C'est l'un des exercices les plus célèbres pour débiter en intelligence artificielle.

Mais un modèle qui réussit sur des images « propres » de laboratoire réussit-il aussi sur de **vraies photos** prises au téléphone ? C'est toute la question de ce document. Nous allons : entraîner un modèle sur le jeu de référence **MNIST**, puis le tester sur un jeu de **chiffres écrits sur papier et photographiés**, et enfin **comparer et analyser** les deux performances.

Le résultat en avant-première

Sur les images de laboratoire (MNIST), le modèle atteint **98.1 %** de bonnes réponses. Sur les images « papier », il tombe à **92.9 %**, soit une baisse de **5.2 points**. Nous verrons pourquoi — et le plus instructif n'est pas la moyenne, mais **quels chiffres** posent problème.

2. MNIST : le jeu de référence

MNIST est une collection de **70 000 images** de chiffres manuscrits, rassemblée pour entraîner et tester des modèles. Chaque image est toute petite : **28 pixels sur 28**, en niveaux de gris. Les chiffres y sont déjà **bien centrés** et détournés sur fond noir.

Un **pixel** est un point de l'image, avec une valeur de 0 (noir) à 255 (blanc). Une image de 28×28 contient donc **784 pixels** : ce sont les 784 nombres que le modèle reçoit en entrée.



Figure — Quelques images de MNIST. Chiffres propres, centrés, en blanc sur fond noir.

On sépare MNIST en deux paquets : **60 000 images** pour **entraîner** le modèle (lui montrer des exemples) et **10 000 images** mises de côté pour le **tester** (vérifier qu'il a vraiment appris sur des images qu'il n'a jamais vues).

3. Le modèle : un réseau de neurones

Pour reconnaître les chiffres, on utilise un **réseau de neurones**. Imaginez une série de « boutons de réglage » (appelés **poids**) que l'on ajuste automatiquement jusqu'à ce que le programme donne les bonnes réponses. Notre réseau, un **perceptron multicouche**, est organisé en couches successives :



Figure — L'information entre par les 784 pixels, traverse deux couches intermédiaires, et ressort en 10 scores (un par chiffre). Le plus haut score gagne.

Les **784** pixels entrent à gauche. Ils traversent deux **couches cachées** (256 puis 128 neurones) qui combinent l'information, et l'on obtient à droite **10 sorties** : un score pour chaque chiffre de 0 à 9. Le chiffre dont le score est le plus élevé est la **réponse du modèle**.

Le mot « apprendre » ici

Apprendre = ajuster les milliers de poids en montrant des exemples au réseau, jusqu'à ce que ses réponses collent aux bonnes étiquettes. Une fois entraîné, le modèle est figé et peut classer de nouvelles images.

4. Entraînement et performance sur MNIST

Après entraînement sur les 60 000 images on mesure la **précision** : le pourcentage d'images correctement reconnues.

	Précision
Sur les images d'entraînement (déjà vues)	99.5 %
Sur les images de test (jamais vues)	98.1 %

La précision de test (**98.1 %**) est ce qui compte vraiment : elle montre que le modèle **généralise** à des images nouvelles, et ne s'est pas contenté de mémoriser. L'écart minime avec l'entraînement indique qu'il n'y a pas de **surapprentissage** important (le fait de trop « coller » aux exemples d'entraînement).

Attention à ce que « 98 % » veut dire

Ce score vaut **uniquement pour des images du même type que MNIST** — propres, centrées, en blanc sur noir. Rien ne garantit encore qu'il tiendra sur de vraies photos. C'est précisément ce que la suite va vérifier.

5. Un jeu de test « réel » : des chiffres sur papier

MNIST est un jeu de **laboratoire** : tout y est propre et régulier. Le monde réel est plus difficile — écritures variées, feuille éclairée de travers, ombres, flou de l'appareil, photo prise de biais. Pour mesurer l'effet de ces conditions, on constitue un **second jeu de test**, représentatif de chiffres écrits sur papier puis photographiés.

Ce jeu contient **2 500 images (250 par chiffre)**. Chaque image est reconstituée à partir d'une **véritable écriture manuscrite** (plusieurs styles d'écriture différents) posée sur une **texture de papier** à laquelle on ajoute les **défauts d'une photo** : éclairage inégal ombres flou grain légère rotation et perspective. Le style d'écriture est donc **volontairement différent** de celui de MNIST — c'est justement ce qui permet de tester la robustesse du modèle.




Figure — En haut : les « photos » de chiffres sur papier. En bas : la même image après prétraitement (voir section 6).

Transparence sur ce jeu de données

Ces images sont **reconstituées** pour imiter des photos réelles de façon reproductible, et non de vrais clichés pris un par un. L'intérêt est de créer un **écart de conditions** mesurable avec MNIST. Le programme fourni accepte aussi de **vraies photos** : il suffit de les déposer dans un dossier, le même prétraitement s'applique.

6. Le prétraitement : d'une photo à une image utilisable

Le modèle n'accepte que des images au **format exact de MNIST** : 28×28, chiffre blanc centré sur fond noir. Une photo brute doit donc être **transformée** avant d'être présentée au modèle. C'est l'étape de **prétraitement**, et elle est décisive : bien faite, elle réduit fortement l'écart avec MNIST. Les étapes :

- **Mise en niveaux de gris** et léger flou pour atténuer le bruit.
- **Inversion** : le chiffre sombre sur papier clair devient clair sur fond sombre (comme MNIST).
- **Séparation encre / papier** par un seuil calculé automatiquement (méthode d'Otsu) : le fond devient noir.

- **Recadrage** sur le chiffre, puis mise à l'échelle à 20×20 en gardant les proportions.
- **Centrage** dans une image 28×28 d'après le « centre de masse », exactement comme MNIST.

La rangée du bas de la figure précédente montre le résultat : des chiffres qui ressemblent beaucoup à MNIST. C'est ce qui permet au modèle de rester performant malgré le changement de conditions.

7. Comparaison des performances

Voici le cœur de l'étude : la même mesure (précision), sur les deux jeux, avec exactement le même modèle.




Figure — Précision globale : MNIST (laboratoire) contre jeu papier (conditions réelles).

Le modèle passe de **98.1 %** à **92.9 %**. Cette baisse de **5.2 points** porte un nom : l'**écart de domaine** (en anglais *domain shift*). Le modèle a appris le « style MNIST » ; confronté à un style d'écriture et à des conditions de prise de vue différents, il se trompe davantage.

Un point de vocabulaire utile

Écart de domaine : la chute de performance d'un modèle quand les données réelles diffèrent de celles sur lesquelles il a été entraîné. C'est l'un des pièges les plus courants — et les plus coûteux — en intelligence artificielle appliquée.

8. Analyse détaillée des résultats

La moyenne cache l'essentiel. En regardant **chiffre par chiffre**, on découvre que la baisse n'est pas répartie uniformément.




Figure — Précision pour chaque chiffre. La plupart restent excellents ; un chiffre s'effondre.

Le constat majeur : le chiffre **1** chute à **66 %** sur le jeu papier, alors qu'il dépassait 99 % sur MNIST. Les autres chiffres, eux, restent proches de leur niveau MNIST.

Où partent les erreurs ? La matrice de confusion

Une **matrice de confusion** croise le **vrai** chiffre (en ligne) et le chiffre **prédit** par le modèle (en colonne). La diagonale = les bonnes réponses. Toute case **hors diagonale** est une erreur, et indique **avec quoi** le chiffre a été confondu.




Figure — Matrice de confusion sur le jeu papier. Les cases hors diagonale révèlent les confusions.

La case la plus parlante : le vrai chiffre **1** a été lu « **7** » **77 fois**. Les confusions suivantes sont $6 \rightarrow 5$ (28 fois) et $8 \rightarrow 0$ (23 fois).

Pourquoi ces confusions ? Regardons les erreurs

En affichant les images mal classées, la cause devient évidente. Les styles d'écriture manuscrite dessinent souvent le chiffre **1** avec un **crochet marqué en haut** — une forme que le modèle, habitué aux « 1 » tout droits de MNIST, prend pour un « 7 ». Ce n'est pas un bug : c'est un vrai désaccord de style entre les deux jeux de données.

Exemples d'erreurs du modèle sur le jeu papier



Figure — Exemples d'images mal classées. « vu X, dit Y » = le vrai chiffre était X, le modèle a répondu Y.

La leçon de cette analyse

Une bonne précision **moyenne** peut masquer une **faiblesse ciblée** et grave. Ici, tout va bien... sauf un chiffre, pour une raison précise et compréhensible. Analyser **par classe** et **par confusion** est indispensable pour savoir à qui se fier.

9. Que retenir, et comment faire mieux

- **Un modèle brillant en laboratoire peut faiblir dans le réel.** Ici, 98.1 % sur MNIST mais 92.9 % sur des photos : c'est l'écart de domaine.
- **La moyenne ne suffit pas.** L'analyse par chiffre et la matrice de confusion révèlent une faiblesse ciblée, invisible dans le score global.
- **Le prétraitement est décisif.** Ramener les photos au format de MNIST (inversion, seuil, recadrage, centrage) limite fortement la chute.

Pistes concrètes pour réduire l'écart

- **Enrichir l'entraînement (data augmentation)** : appliquer aux images MNIST des rotations, flous, ombres et déformations, pour que le modèle voie dès l'entraînement des conditions proches du réel.
- **Ajouter de vraies images** : intégrer quelques centaines de chiffres écrits à la main dans l'entraînement (on parle de *fine-tuning*).
- **Un modèle plus adapté aux images** : un réseau de neurones **convolutif** (CNN) reconnaît mieux les formes et résiste davantage aux variations de style et de position.
- **Cibler la faiblesse connue** : puisqu'un chiffre pose problème, on peut lui fournir davantage d'exemples variés.

En une phrase

Mesurer un modèle sur les données du monde où il sera vraiment utilisé — et non seulement sur son jeu d'entraînement — est la première règle d'un projet d'IA sérieux.

10. Glossaire

MNIST	Collection de 70 000 images (28x28) de chiffres manuscrits, servant de référence pour entraîner et tester des modèles.
Pixel	Un point de l'image, avec une valeur de 0 (noir) à 255 (blanc). Une image 28x28 en compte 784.
Réseau de neurones (MLP)	Modèle formé de couches de « neurones » reliés par des poids ajustables, qui transforme une entrée en une prédiction.
Poids	Les valeurs réglables du réseau. Les « apprendre », c'est les ajuster à partir d'exemples.
Entraînement / Test	On entraîne le modèle sur un paquet d'images, puis on le teste sur d'autres images jamais vues, pour juger honnêtement.
Précision	Pourcentage d'images correctement classées.
Surapprentissage	Quand le modèle mémorise les exemples d'entraînement au lieu de généraliser ; il réussit sur eux mais échoue sur du nouveau.
Prétraitement	Transformer une image brute (photo) pour la mettre au format attendu par le modèle.
Matrice de confusion	Tableau croisant vrais chiffres et chiffres prédits ; montre avec quoi chaque chiffre est confondu.
Écart de domaine	Baisse de performance quand les données réelles diffèrent de celles de l'entraînement (en anglais : domain shift).
Data augmentation	Créer des variantes des images d'entraînement (rotations, flous...) pour rendre le modèle plus robuste.
CNN	Réseau de neurones convolutif, spécialisé dans les images, plus robuste aux variations de forme et de position.